




Анонимизатор медицинских данных



1 Прием
у специалиста



Запись диалога

2 Передача
на сервер



Аудио поступает
в систему

3 Распознавание
речи (ASR)



Специалист: Добрый день!
Как вас зовут?
Клиент: Меня зовут
Иван Иванов.

Специалист: Назовите,
пожалуйста, ваш телефон.
Клиент: +7 900 123-45-67.

Специалист: Ваш адрес
проживания?
Клиент: ул. Ленина, 10.

Специалист: Дата рождения?
Клиент: 15.05.1985.

Специалист: Номер полиса?
Клиент: 461234567890.

Аудио → текст

4 Поиск
персональных
данных



Специалист: Добрый день!
Как вас зовут?
Клиент: Меня зовут Иван Иванов. ФИО

Специалист: Назовите,
пожалуйста, ваш телефон.
Клиент: +7 900 123-45-67. телефон

Специалист: Ваш адрес
проживания?
Клиент: ул. Ленина, 10. адрес

Специалист: Дата рождения?
Клиент: 15.05.1985. дата рождения

Специалист: Номер полиса?
Клиент: 461234567890. номер полиса/
документа

5 Шифрование /
маскирование



Найденные ПДн заменяются
на защищенные значения

Иван Иванов → [ENC_NAME]

+7 900 123-45-67 → [ENC_PHONE]

ул. Ленина, 10 → [ENC_ADDRESS]

Алгоритмы шифрования
и маскирования соответствуют
требованиям безопасности

6 Безопасное хранение
и использование



В системе остаются только
защищенные данные



Хранение



Аналитика



Контроль доступа



Соответствие требованиям закона о защите персональных данных

Обработка персональных данных осуществляется в соответствии с 152-ФЗ
«О персональных данных» и иными требованиями законодательства.



Законность
обработки



Конфиденциальность
данных



Права субъектов
данных




Документирование
и контроль

№	Тип	Что считать чувствительным	Фонетические/ASR-варианты
1	ФИО	любая идентифицирующая часть имени пациента, родителя, доверенного лица: отдельно стоящая фамилия, имя, отчество или их максимальная неразрывная последовательность в одной реплике	иванов, сергей, иванович, иванов сергей петрович
2	ТЕЛЕФОН	мобильный/домашний телефон	поцифрово, блоками, со словами плюс семь, восемь, с повторами
3	АДРЕС	адрес проживания/регистрации/доставки — все относящиеся к адресу компоненты, произнесённые подряд: город, улица, дом, корпус, квартира и т.д.	числа словами или цифрами словами
4	СНИЛС	номер СНИЛС	11 цифр поцифрово или группами 3-3-3-2
5	ПАСПОРТ	серия и номер паспорта как единый span	серия и номер словами/цифрами, с триггерами серия, номер; серия и номер всегда в одном span
6	EMAIL	email	печатный или проговоренный: собака, точка, домен словами
7	ДАТА_РОЖДЕНИЯ	дата рождения	пятое мая тысяча девятьсот..., ноль пятое ноль пятое...
8	ОМС	номер полиса ОМС	16 цифр поцифрово или группами
9	ИНН	ИНН физлица	12 цифр, чаще поцифрово
10	ВОЗРАСТ	возраст пациента — только число (цифра или числительное), без слов «лет», «год», «года»	сорок пять, три, пятьдесят два
11	МЕСТО_РАБОТЫ	название организации-работодателя пациента, без должности	ооо вектор, пао сбер, школа номер двенадцать
12	МСЭ	справка/акт МСЭ, инвалидность	номер, год, суффикс
13	СВИДЕТЕЛЬСТВО	свидетельство о рождении	серия и номер ребенка
14	ВУ	водительское удостоверение	номер после контекста водительских прав
15	TELEGRAM	ник Telegram	собака ivanov123, @ivanov123

Проблемы / нюансы

- Данные шумные из-за ASR
- Отсутствие несинтетического датасета на русском языке для большинства классов
- Отсутствие в свободном доступе персональных данных, как таковых.
- ML часть должна быть не перегруженной: то, что можно поставить в клиниках.
- Публичные LLM в итоговом пайплайне использовать нельзя из-за утечки персональных данных



1 Исходный текст ASR



Клиент: Ну, эээ, мой телефон —
восемь девяносто тринадцать
сто двадцать три сорок пять
шестьдесят семь.

Клиент: Дата рождения —
пятнадцать ноль пять
тысяча девятьсот
восемьдесят пять.

Клиент: Номер полиса —
один два три четыре пять
шесть семь восемь
девять ноль.

шум

междометия

буквенные числа



2 Препроцессинг



A) Удаление междометий

Исключаем шум и междометия

~~—ну—~~ ~~—эээ—~~ ~~—а—~~ ...



B) Нормализация чисел

Преобразуем словесные
числительные в цифры

восемь девяносто тринадцать → 8 913 123 45 67

пятнадцать ноль пять... → 15 05 1985

один два три четыре пять
шесть семь восемь девять ноль → 1234567890

3 Нормализованный текст



Клиент: мой телефон —
8 913 123 45 67.

Клиент: дата рождения —
15 05 1985.

Клиент: номер полиса —
1234567890.



без междометий



цифровой формат



единый вид

4 Поиск числовых ПДн



регулярные выражения

8 913 123 45 67 → [PHONE]

15 05 1985 → [DATE]


1234567890 → [POLICY_ID]




Нормализованный вид
упрощает распознавание
числовых персональных данных

Генерация


Для генерации данные были разделены на числовые (паспорт, СНИЛС) и словесные (адрес, фамилия). Для числовых данных был написан валидный генератор, а словесные взяты из открытых источников. Для создания размеченного датасета будет использоваться LLM, которая будет генерировать контекст, содержащий наши данные.





Что уже сделано

- Выработаны метрики оценки конечной модели.
- Найдены работающие аналоги.
- Кластеризованы персональные данные.
- Собраны необходимые датасеты по каждому классу.
- Найдены синтетические датасеты.
- Реализован препроцессинг.



Что планируем делать дальше

- Собрать качественный датасет, приближенный к реальности, из уже найденных данных.
- Подготовить данные для обучения, валидации, тестирования.
- Обучить ML-модель.
- Сравнить результаты с существующими решениями.

