




Anon Med

Анонимизация медицинских ASR текстов

PRIVACY-FIRST | AI-POWERED | RULES + ML | RESTORABLE



ASR TRANSCRIPT + PREPROCESSING

Пациент Иванов Сергей Петрович, 1978 года рождения,
проживает по адресу: ул. Лесная, д. 12, кв. 34.
телефон 89131234567
СНИЛС: 123-456-789 01. Паспорт: 45 12 345678.
Жалобы на головную боль и слабость...



00:00:12

MASKED TEXT

Пациент [PER], [DATE_BIRTH] года рождения,
проживает по адресу: [ADDRESS].
телефон [PHONE]
СНИЛС: [SNILS]. Паспорт: [PASSPORT].
Жалобы на головную боль и слабость...

- PER
- PHONE
- SNILS
- PASSPORT
- ADDRESS

PREPROCESSING



Normalization
Sentence split
Tokenization

RULE-BASED



Regex / Patterns
Dictionaries
Heuristics

ML DETECTION



NER Models
Contextual cues
Ensembling

POSTPROCESSING



Conflict resolution
Span merging
Consistency

RESTORATION



Reversible mapping
Secure storage
Audit trail

> _anonmed / quick start

```
from anonmed import PIIAnonymizer
anonymizer = PIIAnonymizer()
result = anonymizer(
    "ну, телефон: восемь девять один три один два три четыре пять шесть семь"
)
print(result.preprocessed_text)
# телефон 89131234567
print(result.masked_text)
# ну, телефон: [PHONE]!
```

Анонимизация медицинского ASR


запись приема → текст → маскирование ПДн

local pipeline

no raw PII

Клиника

голосовой помощник
пишет диалог



```
from anonmed import anonymize_pii

result = anonymize_pii(
    "назовите ваш паспорт, пожалуйста"
    "окей, сейчас, мой паспорт серия сорок пять одиннадцать номер "
    "семьсот восемьдесят девять триста двадцать четыре" ,
    use_ml=False,
)

print(result.masked_text)
# паспорт серия [PASSPORT]
```

raw number never leaves the local contour

[PASSPORT]

Сервер получает
только очищенный
текст



[NAME]

[PHONE]

[DATE]

диалог

ASR

PII detector


masking

analytics

правила + локальная ML часть

Ограничения / Требования

- Шумный ASR-текст
- Дефицит реальных RU-данных
- Локальная легковесная ML-модель
- Без внешних LLM
- Корпоративно совместимые лицензии



Preprocessing

Проблема шумного ASR решается preprocessing


Удаляет междометия, нормализует текст, исправляет шаблонные ошибки ASR и переводит текстовые числа в цифры для последующей обработки регулярными выражениями.



```
1 from anonmed import PIIAnonymizer
2 anonymizer = PIIAnonymizer()
3
4 result = anonymizer(
5     "ну, телефон: восемь девять один три один два три четыре пять шесть семь!"
6 )
7
8
9 print(result.preprocessed_text)
10 # телефон 89131234567
```

Существующие решения


- Natasha
- GLiNER
- Personal-information-detection-russian (PIDR)
- Pullenti



GLiNER2: F1 / Precision / Recall

сравнение метрик по выбранным запускам


F1 Precision Recall



GLiNER2: Precision vs Recall

правый верхний угол — лучший результат


run point ideal corner



Блок ML

Для гибкого тестирования и запуска моделей были реализованы абстракция и скрипты для автоматического прогона:

- Подключение новых моделей и датасетов
- Создание метрик
- Конфигурирование запусков



Restore non PII text + postprocess

Восстановление удаленного контекста




```
1 from anonmed import PIIAnonymizer
2 anonymizer = PIIAnonymizer(ml_model="natasha_per")
3
4 result = anonymizer(
5     "- Здравствуйте, я с жалобой на сыпь. - Добрый день, ну, давайте посмотрим,
6     только назовите имя.- Иванова Ирина Оле... а, ой, подождите, дочь звонит."
7 )
8
9 print(result.preprocessed_text)
10 # можно войти
11 # конечно проходите
12 # Что Вас беспокоит у меня 4 день
13 # очень сильно болит горло
14
```

```
15 print(result.masked_text)
16 # - Здравствуйте, я с жалобой на сыпь.
17 # - Добрый день, ну, давайте посмотрим, только назовите имя.
18 # - [PER]... а, ой, подождите, дочь звонит.
19
20
21
```



Pipeline генерации диалогов состоит из:

- генерации текстов по контекстам через LLM
- сокращения этих текстов до более мелких
- удаления плохих диалогов
- разметки текста

сгенерированный нами




найденный в интернете



AnonMed Pipeline



PHONE SNILS PASSPORT



пример полного прохода
пайпайна

«ну, телефон: восемь девять один три...»



телефон 89131234567



[PHONE]



«ну, телефон: [PHONE]»

без отправки ПДн в публичные
LLM

Python API

CLI


JSON

structured result


Metric anonymizer pipeline

In-the-wild dataset 1 · limit=1000 · ml_model=natasha_per · entity_soft

soft F1




precision / recall




Шаги развития

- Улучшение генерации синтетических данных.
- Улучшение сохранения нерелевантных данных.
- Дообучение моделей.
- Удаление нетривиальных повторений.
- Внедрение ML в препроцессинг.



Материалы

Основные ссылки проекта



Репозиторий

 <https://github.com/DFT-Enjoyer/AnonMed/>



Вики

 <https://dashing-ochre-mink.slab.com/register/zgw4j7wd/GbPw68VtX4NmQ39ahsxJ5cny>

